

كارت المراجعة — آخر ١٠ دقائق

١. الأرقام اللي لازم تيجي من غير تفكير

commit لكل commit · 3.45 run 2,835 من workflow runs	9,772
repositories · 89.03 / 10.97 success / failure	18
الرقم الأساسي — failure F1, XGBoost	0.0638 ± 0.4216
PR-AUC · ROC-AUC	0.8240 · 0.4803
categorical_only — كسب الموديل الكامل	0.4808
structured_only — يعني النص مبيضيفش	0.4225
text_only	0.1962
ال threshold المختار (متوسط ٥ folds)	0.076
التقييم الزمني — ٢~ نقطة أقل، متسق	0.399
التقدير السنوي · نقطة التعادل \$20.41	\$243,670

٢. سلم النسب — احفظه بالترتيب

أكبر من الأولى ← test على الـ threshold -0.126 commit leakage الرقم القديم -0.060 0.5924
الرقم الأمين 0.4216 — folds بالضعف +0.015 متوسط على ٥

«كل خطوة اتعملت لوحدها على نفس الداتا ونفس ال seed. أنا قِست التكلفة مش قدّرتها.»

٣. التلات سكربتات — الجُمَل المفتاحية بس

CI/CD (سلايد ٣ و ٤) — ابدأ بيها من غير ما حد يسأل

«تخلوا إن كل مرة طالب يسلم فصل، الجامعة تشغل عليه برنامج أوتوماتيك يراجع ويرد: مقبول ولا مرفوض. مفيش إنسان — مكنة.

GitHub الدولاب المشترك · commit التعديل المحفوظ · CI/CD المكنة اللي بتفحص.

وبحني ببسأل: في لحظة حفظ التعديل، قبل المكنة تشتغل، نقدر نتوقع إنها «تفشل؟»

بعدها: ١١٪ بس بيفشل — علشان كده ال accuracy مالهاش لازمة.

الأرقام نزلت ليه (سلايد ٢٠ و ٢١)

«نفس الموديل ونفس الداتا. الموديل مبقاش أسوأ — المسطرة بقت أمينة. غلطتين: ٩٧٧٢ run من ٢٨٣٥ commit بس، والتقسيم العشوائي كان بيحط نسخ من نفس ال commit على الجنين. والثانية إنني كنت بختار ال threshold على ال test نفسه. ٠.٠٦٠ و ٠.١٢٦. والأقل وضوحاً كلّفت الضعف. وأنا اللي لقيتها وقستها وصلحتها ونشرتها في قسم ٧.٤.٥.»

«إدیت المودیل بس اسم المشروع وال workflow والفرع والحدث. كسب المودیل الكامل فی كل مقياس — 0.4808 مقابل 0.4216. ودي بتكدّب فرضيتي. النظام **project-level risk estimator**، مش **commit-level**. وأنا اللي عملت التجربة دي، لأنها أخرج سؤال ممكن يتسأل.»

٤. الفخاخ — إجابة سطر واحد لكل واحد

السؤال	الرد
«رقمك أقل من ٠.٨٨»	«أقوى feature عندهم بال SHAP هي build duration — معروفة بعد التنفيذ. وعدم التوازن عندهم ٢٢٪ مقابل ١١٪ عندي، ومتغيرهم ٤ فئات»
«إزاي elasticsearch صفر؟»	«٥٩١ من ٦٠٠ (٩٨٪) شغل docs و checksum. ال CI الحقيقي بتاعهم على Buildkite. مكتوبة كحد ٧ في قسم ٨.٣»
«ليه XGBoost وهو أسوأ F1 عند 0.5؟»	«اختبرته على PR-AUC = 0.480 . والثلاثة بيفرقوا أقل من ٠.٠١ والانحراف أكبر من ٠.٠٦ — مفيش فايز على F1»
«ال 0.5 اختيارك؟»	«لأ — الافتراضي المدفون في sklearn، معايير لكلاسين متوازنين»
«١٨ مشروع قليلين»	«مكتوبة كحد ٣. والحد الأعمق اللي قيسته إن ال runs نفسها مش متكافئة»
«يعني كنت غلطان؟»	«في القياس، أيوه. Kapoor و Narayanan لقوا نفس الغلط في ٢٩٤ ورقة في ١٧ مجال»
سؤال كود مش عارفه	«مش فاكتر بالطبط و مش عايز أقول غلط. الملف معايا وأقدر أوريك السطر»

٥. الكود — ثلاث نقط بس

الملف	السطر	إيه
data_preparation.py	490	GroupShuffleSplit مش grouped split · StratifiedGroupKFold لأن التانية متعملش stratify (٩.٧١% مقابل ١٤.٧٢%)
cross_validation.py	96	ال inner split اللي بيختار ال threshold — أبدأ مش على test
run_corrected_evaluation.py	104	سلم النسب

الجملة اللي بتنقذك في أي سؤال كود:

«كل رقم بيتولّد من results/*.json بأمر واحد. مفيش رقم مكتوب بإيدي. ./reproduce.sh — ٣ دقائق.»

٦. اعمل / ما تعملش

اعمل - اشرح CI/CD الأول، من غير ما حد يطلب - اذكر نواقصك قبل اللجنة — كلها مقيسة - اتكلم بالراحة. اللجنة مش فاهمة المجال

ما تعملش - ما تقولش إنك أحسن من الأبحاث السابقة — رقمك أقل والسبب مشروع - ما تعتذر عن 0.42 — دي نتيجة مقيسة - ما تفتحش ال CSV الخام — افتح Dataset_Guide.xlsx - ما تخترعش رقم

٧. الجملة اللي بتكسب الموقف

«أنا اللي لقيت الغلط بنفسي، وقست تأثيره بالضبط، وصلحته، ونشرت التصحيح جوه الرسالة. وده اللي المنهج العلمي المفروض يعمل.»

لو نسيت كل حاجة

0.4216

بالتوفيق.